

LAPORAN ANALISIS KODE MACHINE LEARNING

Unsupervised Learning



Disusun Oleh:

Nama : Judika Ebenzer Sianturi

NPM : G1A024031

Kelas : A

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Machine Learning merupakan salah satu bidang dalam kecerdasan buatan yang memungkinkan komputer mempelajari pola dari data dan menghasilkan suatu keluaran berdasarkan pola yang ditemukan. Keberhasilan suatu metode machine learning tidak hanya bergantung pada algoritma yang digunakan, tetapi juga pada bagaimana data dipersiapkan sebelum diberikan kepada model. Perbedaan skala antarfitur, jumlah dimensi yang tinggi, serta bentuk distribusi data dapat memengaruhi hasil pemodelan secara signifikan.

Notebook praktikum ini mengacu pada Bab 3 buku "Introduction to Machine Learning with Python" karya Andreas C. Müller dan Sarah Guido, yang membahas unsupervised learning dan prapemrosesan data. Salah satu tahapan penting dalam pengolahan data adalah preprocessing atau scaling, yang bertujuan menyelaraskan rentang nilai antarfitur. Beberapa teknik scaling yang dibahas meliputi MinMaxScaler dan StandardScaler, beserta pengaruhnya terhadap performa algoritma supervised learning seperti Support Vector Machine.

Selain preprocessing, data machine learning sering memiliki jumlah fitur yang cukup banyak (dimensi tinggi), sehingga menyulitkan proses visualisasi dan meningkatkan kompleksitas komputasi. Untuk mengatasi hal ini, digunakan teknik reduksi dimensi berupa Principal Component Analysis (PCA) dan Non-negative Matrix Factorization (NMF). PCA diterapkan pada dataset Breast Cancer serta dataset citra wajah (Labeled Faces in the Wild) melalui pendekatan Eigenfaces, sementara NMF digunakan untuk ekstraksi komponen non-negatif pada citra wajah maupun pemisahan sumber sinyal (blind source separation).

Untuk keperluan visualisasi data berdimensi tinggi, digunakan pula teknik manifold learning t-SNE pada dataset Digits, yang dibandingkan dengan hasil PCA dua komponen. Selain reduksi dimensi, notebook ini membahas pendekatan unsupervised learning berupa clustering, yaitu proses mengelompokkan data berdasarkan kemiripan karakteristiknya tanpa menggunakan label kelas. Tiga algoritma clustering yang dianalisis adalah K-Means, Agglomerative Clustering, dan DBSCAN, yang masing-masing memiliki pendekatan berbeda dalam membentuk kelompok data serta kelebihan dan keterbatasan pada berbagai bentuk struktur data, termasuk dataset Two Moons yang bersifat non-konveks.

Evaluasi performa clustering juga dibahas menggunakan metrik dengan ground truth (Adjusted Rand Index) maupun tanpa ground truth (Silhouette Score), serta perbandingan

ketiga algoritma clustering pada dataset citra wajah untuk melihat bagaimana masing-masing algoritma menangani data dunia nyata yang kompleks.

1.2 Tujuan

- Memahami berbagai teknik preprocessing/scaling data (MinMaxScaler, StandardScaler) dan pengaruhnya terhadap performa algoritma supervised learning.
- Memahami konsep reduksi dimensi menggunakan Principal Component Analysis (PCA) dan Non-negative Matrix Factorization (NMF).
- Menganalisis penerapan PCA dan NMF pada dataset citra wajah (Eigenfaces) serta pada kasus pemisahan sumber sinyal sintetis.
- Memahami penggunaan t-SNE sebagai teknik visualisasi data berdimensi tinggi.
- Menganalisis karakteristik, kelebihan, dan keterbatasan algoritma clustering K-Means, Agglomerative Clustering, dan DBSCAN.
- Memahami metrik evaluasi clustering, baik dengan maupun tanpa ground truth.
- Mengembangkan kemampuan praktis dalam implementasi unsupervised learning menggunakan scikit-learn.

BAB II

METODOLOGI DAN OUTPUT EKSPERIMEN

2.1 Preprocessing dan Scaling

Sebelum masuk ke algoritma unsupervised learning, dibahas terlebih dahulu konsep preprocessing atau scaling data. Ilustrasi dasar (plot_scaling) menunjukkan bagaimana beberapa teknik scaling, yaitu StandardScaler, MinMaxScaler, RobustScaler, dan Normalizer, mengubah representasi data yang sama dengan cara berbeda. StandardScaler menstandarkan data agar memiliki rata-rata nol dan varians satu, MinMaxScaler mengubah rentang nilai fitur menjadi antara 0 dan 1, RobustScaler menggunakan median dan rentang interkuartil sehingga lebih tahan terhadap outlier, sedangkan Normalizer menormalisasi setiap sampel (baris) alih-alih setiap fitur (kolom).

2.2 Penerapan MinMaxScaler pada Dataset Breast Cancer

Dataset Breast Cancer Wisconsin (569 sampel, 30 fitur) dibagi menjadi data training dan testing menggunakan train_test_split. MinMaxScaler kemudian di-fit hanya pada data training, lalu digunakan untuk mentransformasikan baik data training maupun data testing. Hasilnya menunjukkan bahwa setelah scaling, nilai minimum dan maksimum setiap fitur pada data training berada tepat pada rentang 0 dan 1. Namun, karena parameter scaler (nilai minimum dan rentang) dihitung dari data training, nilai fitur pada data testing setelah transformasi tidak selalu berada tepat pada rentang $[0, 1]$ - beberapa nilai bisa sedikit di luar rentang tersebut, yang merupakan perilaku wajar dan diharapkan.

2.3 Pentingnya Scaling yang Konsisten antara Data Training dan Testing

Menggunakan dataset sintesis make_blobs yang dibagi menjadi data training dan testing, dibandingkan tiga kondisi: data asli (Original Data), data yang di-scaling dengan benar (Scaled Data - scaler di-fit pada training lalu diterapkan ke keduanya), dan data yang di-scaling secara tidak tepat (Improperly Scaled Data - scaler di-fit secara terpisah untuk training dan testing). Pada kondisi scaling yang benar, posisi relatif titik data testing terhadap data training tetap konsisten. Sebaliknya, pada scaling yang tidak tepat, posisi data testing berubah signifikan sehingga tidak lagi sebanding dengan data training, karena kedua himpunan data ditransformasikan menggunakan parameter skala yang berbeda. Hal ini menegaskan prinsip penting: proses fit hanya dilakukan pada data training, kemudian transformasi yang sama (dengan parameter yang sama) diterapkan pada data testing.

2.4 Pengaruh Preprocessing terhadap Performa Supervised Learning

Untuk menunjukkan dampak nyata scaling terhadap performa model, SVC (Support Vector Classifier) dilatih pada dataset Breast Cancer dalam tiga kondisi: tanpa scaling, dengan scaling MinMaxScaler (0-1), dan dengan scaling StandardScaler (zero mean, unit variance). Tanpa preprocessing, SVC menghasilkan akurasi test yang relatif rendah karena algoritma berbasis jarak seperti SVM sangat sensitif terhadap perbedaan skala antarfitur. Setelah diterapkan MinMaxScaler maupun StandardScaler, akurasi test meningkat signifikan, membuktikan bahwa preprocessing bukan sekadar langkah opsional, melainkan tahapan krusial yang memengaruhi hasil akhir model secara langsung.

2.5 Reduksi Dimensi dengan Principal Component Analysis (PCA) - Ilustrasi Dasar

Ilustrasi dasar PCA (`plot_pca_illustration`) memperlihatkan bagaimana PCA mencari arah (komponen) dengan variasi data terbesar pada data dua dimensi. Komponen pertama menunjukkan arah dengan variasi terbesar, sedangkan komponen kedua tegak lurus terhadap komponen pertama dan menangkap variasi sisanya. Data kemudian dapat ditransformasikan ke ruang komponen utama, direduksi dengan menghilangkan komponen yang kurang informatif, dan direkonstruksi kembali (back-rotation) ke ruang fitur asli, meskipun sebagian informasi akan hilang akibat proses reduksi tersebut.

2.6 Analisis Distribusi Fitur pada Dataset Breast Cancer

Sebelum menerapkan PCA, dilakukan analisis histogram terhadap 30 fitur dataset Breast Cancer, dibedakan berdasarkan kelas malignant dan benign. Beberapa fitur seperti mean radius, mean perimeter, dan mean area menunjukkan perbedaan distribusi yang cukup jelas antara kedua kelas, sedangkan sebagian fitur error dan fractal dimension menunjukkan tumpang tindih yang lebih besar. Analisis ini juga memperlihatkan bahwa setiap fitur memiliki rentang nilai yang sangat berbeda, memperkuat alasan pentingnya scaling sebelum diterapkan PCA, karena PCA sensitif terhadap skala fitur.

2.7 Visualisasi PCA Dua Komponen pada Dataset Breast Cancer

Setelah data distandardisasi menggunakan StandardScaler, PCA dengan dua komponen (`n_components=2`) diterapkan untuk mereduksi 30 fitur menjadi dua komponen utama. Scatter plot hasil transformasi menunjukkan bahwa kelas malignant dan benign membentuk pola distribusi yang cukup berbeda pada ruang dua komponen ini, meskipun masih terdapat area tumpang tindih di bagian tengah. Hasil ini menegaskan bahwa PCA dapat digunakan untuk memvisualisasikan struktur data berdimensi tinggi sekaligus mempertahankan pola pemisahan kelas yang bermakna, walau bersifat unsupervised (label kelas tidak digunakan dalam proses pembentukan komponen).

2.8 Interpretasi Komponen Utama PCA

Untuk memahami kontribusi setiap fitur terhadap dua komponen utama, digunakan heatmap dari `pca.components_`. Baris pertama merepresentasikan First component dan baris kedua Second component, sedangkan setiap kolom mewakili satu dari 30 fitur asli. Pada komponen pertama, hampir seluruh fitur memberikan kontribusi positif dengan bobot yang relatif seragam, mengindikasikan bahwa komponen ini banyak merepresentasikan ukuran keseluruhan sel (radius, perimeter, area). Komponen kedua menunjukkan kombinasi bobot positif dan negatif yang lebih beragam antarfitur, mencerminkan pola variasi kedua yang berbeda dari ukuran umum sel.

2.9 Eigenfaces untuk Ekstraksi Fitur pada Dataset LFW

Dataset Labeled Faces in the Wild (LFW) diambil menggunakan `fetch_lfw_people` dengan parameter `min_faces_per_person=20`, menghasilkan kumpulan citra wajah berukuran seragam. Untuk menyeimbangkan jumlah sampel per kelas, digunakan masking sehingga maksimal 50 citra per orang diambil. Sebuah eksperimen awal menggunakan `KNeighborsClassifier` ($k=1$) pada piksel mentah menghasilkan akurasi yang relatif rendah, menunjukkan keterbatasan penggunaan piksel mentah sebagai fitur langsung untuk klasifikasi wajah.

2.10 PCA dengan Whitening

Ilustrasi `plot_pca_whitening` memperlihatkan efek parameter `whiten=True` pada PCA, yaitu menskalakan setiap komponen utama sehingga memiliki skala yang seragam, mirip dengan proyeksi menggunakan `StandardScaler` pada ruang komponen. PCA dengan `whiten=True` dan 100 komponen kemudian diterapkan pada data wajah training, dan `KNeighborsClassifier` dilatih pada representasi berdimensi rendah tersebut (bukan piksel mentah). Hasilnya menunjukkan peningkatan akurasi test yang signifikan dibandingkan percobaan sebelumnya, membuktikan bahwa PCA berhasil mengekstraksi fitur yang lebih informatif dari citra wajah berdimensi tinggi.

2.11 Rekonstruksi Wajah dengan PCA (Eigenfaces)

Komponen-komponen utama hasil PCA (`pca.components_`) divisualisasikan kembali sebagai citra wajah (Eigenfaces), menunjukkan pola visual yang berkontribusi terhadap variasi wajah dalam dataset, bukan wajah individu tertentu. Fungsi `plot_pca_faces` kemudian mendemonstrasikan proses rekonstruksi citra wajah menggunakan jumlah komponen utama yang berbeda-beda (misalnya 10, 50, 100, hingga 500 komponen): semakin banyak komponen yang digunakan, semakin mirip hasil rekonstruksi dengan citra asli, sementara dengan sedikit komponen, rekonstruksi hanya menangkap pola wajah secara umum. Scatter plot dua

komponen pertama dari data wajah yang ditransformasikan PCA juga menunjukkan bahwa titik-titik dari kelas (orang) berbeda cenderung tersebar dan saling tumpang tindih, mengindikasikan bahwa dua komponen saja belum cukup untuk memisahkan identitas wajah secara jelas.

2.12 Non-Negative Matrix Factorization (NMF) pada Data Sintetis

Ilustrasi `plot_nmf_illustration` membandingkan hasil NMF dengan satu dan dua komponen pada data sintetis. Berbeda dengan PCA yang komponennya dapat berupa kombinasi positif maupun negatif, komponen NMF bersifat non-negatif, sehingga representasinya dapat dipandang sebagai kombinasi aditif dari beberapa komponen dasar. Karakteristik ini membuat NMF cocok digunakan pada data yang secara alami bernilai non-negatif, seperti intensitas piksel citra.

2.13 NMF pada Citra Wajah

NMF dengan 15 komponen (`n_components=15`) diterapkan pada dataset wajah LFW menggunakan `plot_nmf_faces`, menghasilkan komponen-komponen yang menangkap pola visual tertentu pada citra wajah, seperti area wajah dominan, rambut, atau latar belakang. Eksperimen lanjutan mengurutkan citra berdasarkan nilai komponen tertentu (misalnya komponen ke-3) untuk melihat contoh wajah dengan kontribusi terbesar pada komponen tersebut, menunjukkan bahwa setiap komponen NMF berkaitan dengan pola visual spesifik pada sekumpulan citra wajah yang memiliki karakteristik serupa.

2.14 Pemisahan Sumber Sinyal dengan NMF (Blind Source Separation)

Menggunakan data sintetis `mglearn.datasets.make_signals()` berupa tiga sinyal sumber, dibuat data campuran berdimensi 100 melalui perkalian dengan matriks acak, mensimulasikan pengukuran dari beberapa sensor yang masing-masing menangkap kombinasi dari sinyal-sinyal asli. NMF dengan tiga komponen (`n_components=3`) kemudian diterapkan untuk merekonstruksi sinyal sumber dari data campuran tersebut, dan hasilnya dibandingkan dengan PCA tiga komponen pada data yang sama. Sinyal hasil rekonstruksi NMF secara visual lebih menyerupai pola sinyal sumber asli (True sources), sedangkan sinyal hasil PCA tampak berbeda dan tidak konsisten dengan sumber sebenarnya. Hal ini terjadi karena NMF secara alami cocok untuk data yang bersifat aditif dan non-negatif seperti sinyal campuran, sementara PCA hanya berfokus mencari arah variasi terbesar tanpa mempertimbangkan sifat aditif tersebut.

2.15 Visualisasi Manifold dengan t-SNE pada Dataset Digits

Dataset Digits (citra angka tulisan tangan 8x8 piksel) divisualisasikan terlebih dahulu dalam bentuk grayscale untuk melihat karakteristik datanya. PCA dua komponen kemudian

diterapkan untuk mereduksi dimensi data, namun hasilnya menunjukkan bahwa kelas-kelas angka masih banyak bertumpang tindih pada ruang dua dimensi. Sebagai perbandingan, TSNE (t-Distributed Stochastic Neighbor Embedding) diterapkan menggunakan `fit_transform` (karena t-SNE tidak memiliki metode transform terpisah, sehingga tidak dapat diterapkan pada data baru). Hasil t-SNE menunjukkan pemisahan kelompok angka yang jauh lebih jelas dibandingkan PCA, karena t-SNE dirancang khusus untuk mempertahankan struktur lokal (kedekatan antar titik tetangga) sehingga lebih unggul untuk keperluan visualisasi, meskipun bersifat non-linear dan tidak dapat digunakan untuk mentransformasikan data baru seperti PCA.

2.16 Algoritma K-Means Clustering

Mekanisme dasar K-Means diilustrasikan melalui `plot_kmeans_algorithm`, menunjukkan proses iteratif inisialisasi centroid, penetapan setiap titik ke centroid terdekat (`assign points`), pembaruan posisi centroid berdasarkan rata-rata anggotanya (`recompute centers`), dan pengulangan hingga konvergen. Selanjutnya, `KMeans(n_clusters=3)` diterapkan pada dataset sintetis `make_blobs`, dengan hasil `cluster_centers_` dan `labels_` divisualisasikan bersama titik data. Eksperimen tambahan membandingkan hasil clustering dengan jumlah cluster berbeda (`n_clusters=2` dan `n_clusters=5`) untuk menunjukkan bagaimana pemilihan jumlah cluster memengaruhi bentuk pengelompokan yang dihasilkan.

2.17 Kegagalan K-Means pada Struktur Data Tertentu

K-Means memiliki asumsi bahwa setiap cluster berbentuk konveks (membulat) dan memiliki ukuran yang relatif seragam, sehingga beberapa kondisi data dapat menyebabkan kegagalan pengelompokan. Pada data dengan varians cluster yang berbeda-beda (`cluster_std` bervariasi), K-Means cenderung salah menetapkan titik-titik pada cluster dengan varians besar ke cluster tetangganya. Pada data yang ditransformasikan secara anisotropik (diregangkan/dimiringkan menggunakan transformasi linear), K-Means gagal mengikuti bentuk cluster yang memanjang karena hanya mempertimbangkan jarak Euclidean ke centroid. Demikian pula pada dataset Two Moons yang berbentuk dua bulan sabit (non-konveks), K-Means gagal memisahkan kedua bulan sabit tersebut secara benar karena keduanya dipotong berdasarkan jarak ke centroid, bukan berdasarkan bentuk struktur data yang sebenarnya.

2.18 K-Means sebagai Teknik Vector Quantization

Bagian ini menunjukkan sudut pandang alternatif terhadap K-Means, yaitu sebagai teknik dekomposisi (vector quantization), di mana setiap titik direpresentasikan oleh satu centroid meskipun jumlah cluster jauh lebih besar dari jumlah komponen PCA/NMF yang setara. Pada dataset wajah, K-Means dengan jumlah cluster besar (misalnya 10) diterapkan pada data hasil

reduksi NMF, dan komponen-komponen yang diekstraksi divisualisasikan sebagai citra wajah. Selain itu, ditunjukkan bahwa hasil `transform()` dari KMeans dapat digunakan sebagai fitur jarak (distance features) ke setiap centroid, sehingga K-Means juga dapat berperan sebagai teknik ekstraksi fitur, khususnya berguna pada dataset seperti Two Moons yang tidak dapat dipisahkan secara linear oleh model klasifikasi sederhana.

2.19 Agglomerative Clustering dan Dendrogram

Agglomerative Clustering diilustrasikan melalui `plot_agglomerative_algorithm`, menunjukkan proses penggabungan cluster secara hierarkis dari bawah ke atas (bottom-up): setiap titik data awalnya dianggap sebagai cluster tersendiri, kemudian dua cluster yang paling mirip digabungkan secara berulang hingga mencapai jumlah cluster yang diinginkan. `AgglomerativeClustering(n_clusters=3)` diterapkan pada dataset `make_blobs` dengan hasil yang divisualisasikan. Selanjutnya, dendrogram dibangun menggunakan fungsi `ward` dari SciPy untuk memvisualisasikan seluruh proses penggabungan cluster secara hierarkis dalam bentuk pohon, di mana panjang setiap cabang merepresentasikan jarak antar cluster yang digabungkan - representasi ini memberikan gambaran yang lebih kaya dibandingkan sekadar label cluster akhir, karena pengguna dapat memilih jumlah cluster dengan memotong dendrogram pada ketinggian tertentu.

2.20 DBSCAN (Density-Based Spatial Clustering)

Berbeda dari K-Means dan Agglomerative Clustering yang memerlukan jumlah cluster ditentukan di awal, DBSCAN mengelompokkan data berdasarkan kepadatan (density) dan secara otomatis dapat mengidentifikasi titik-titik yang dianggap sebagai noise (diberi label -1). Pengujian awal pada dataset kecil menunjukkan bahwa dengan parameter default, seluruh titik justru diklasifikasikan sebagai noise karena parameter `eps` (radius tetangga) terlalu kecil relatif terhadap skala data. Ilustrasi `plot_dbscan` menunjukkan bagaimana parameter `eps` dan `min_samples` memengaruhi hasil pengelompokan. Pada dataset Two Moons yang telah distandardisasi (`StandardScaler`), DBSCAN berhasil memisahkan kedua bulan sabit dengan sempurna, sebuah hasil yang tidak dapat dicapai oleh K-Means maupun Agglomerative Clustering, karena DBSCAN tidak mengasumsikan bentuk cluster tertentu dan mampu mengikuti struktur data non-konveks berdasarkan kepadatan lokal.

2.21 Evaluasi Clustering dengan Ground Truth: Adjusted Rand Index (ARI)

Untuk mengevaluasi kualitas clustering secara kuantitatif ketika label sebenarnya (ground truth) tersedia, digunakan Adjusted Rand Index (ARI). Berbeda dengan `accuracy_score` biasa yang mensyaratkan label prediksi identik persis dengan label asli, ARI dirancang khusus untuk clustering karena penomoran cluster bersifat arbitrer (permutasi label yang berbeda tetap

dianggap sebagai pengelompokan yang sama secara struktural). Perbandingan pada dataset Two Moons menunjukkan bahwa K-Means dan Agglomerative Clustering menghasilkan ARI yang jauh dari sempurna karena keduanya gagal mengikuti bentuk non-konveks data, sedangkan DBSCAN pada data yang telah distandardisasi mencapai ARI mendekati atau tepat 1,00, menandakan pengelompokan yang identik dengan struktur sebenarnya.

2.22 Evaluasi Clustering tanpa Ground Truth: Silhouette Score

Pada kondisi nyata, label ground truth sering kali tidak tersedia, sehingga diperlukan metrik evaluasi intrinsik seperti Silhouette Score, yang mengukur seberapa padat suatu cluster dan seberapa jauh jaraknya dari cluster lain, tanpa memerlukan label sebenarnya. Perbandingan Silhouette Score pada dataset Two Moons menunjukkan bahwa metrik ini tidak selalu sejalan dengan ARI: K-Means dapat memperoleh Silhouette Score yang relatif baik karena menghasilkan cluster yang kompak dan membulat, meskipun secara struktural gagal memisahkan kedua bulan sabit dengan benar. Hal ini menjadi catatan penting bahwa metrik berbasis bentuk geometris seperti Silhouette Score tidak selalu mampu menilai kesesuaian clustering terhadap struktur data yang kompleks atau non-konveks.

2.23 Perbandingan Algoritma Clustering pada Dataset Wajah

Sebagai studi kasus dunia nyata, ketiga algoritma clustering dibandingkan pada dataset wajah LFW yang telah direduksi dimensinya menggunakan PCA (whiten=True, 100 komponen). Pada DBSCAN, parameter eps dan min_samples divariasikan secara sistematis: dengan parameter default sebagian besar titik dianggap noise, sedangkan setelah eps diperbesar (misalnya eps=15), sebagian besar data berhasil dikelompokkan ke dalam satu cluster utama dengan sejumlah kecil titik yang teridentifikasi sebagai noise/outlier - citra-citra pada cluster noise umumnya menunjukkan variasi pose, ekspresi, atau kondisi pencahayaan yang tidak biasa. Pada K-Means dengan 10 cluster, setiap centroid divisualisasikan sebagai citra wajah rata-rata dari anggotanya, dan gambar-gambar yang paling dekat/jauh dari tiap centroid ditampilkan untuk melihat homogenitas tiap cluster. Pada Agglomerative Clustering dengan 10 cluster, dendrogram dan visualisasi anggota tiap cluster menunjukkan pengelompokan yang lebih beragam dibandingkan K-Means. Perbandingan ARI antara hasil K-Means dan Agglomerative Clustering menunjukkan tingkat kesepakatan yang relatif rendah, mengindikasikan bahwa kedua algoritma menangkap struktur pengelompokan yang cukup berbeda pada data wajah yang kompleks ini. Eksperimen lanjutan dengan memperbanyak jumlah cluster Agglomerative (n_clusters=40) menghasilkan kelompok-kelompok yang lebih homogen dan lebih mudah diinterpretasikan secara visual.